

데이팅 플랫폼을 위한 이탈 예측 · 리텐션 서비스

Catch

이탈 가능성이 높은 사용자를 미리 찾아내고,
어떤 전략을 적용할지까지 제안합니다.

SKN36-2nd-3Team · 강민지 · 김재훈 · 신지수 · 임성경

PROBLEM

문제 정의



신규 유입만큼, 가입한 사용자를 계속 이용하게 하는 것도 중요해요



OkCupid 사용자 프로필 약 6만 명

연령 · 직업 · 학력 · 자녀 여부 · 흡연 여부 · 자기소개 작성 정도 등



그런데 실제 탈퇴 여부가 데이터에 없어요

마지막 접속 시점(last_online)으로 장기 미접속 사용자를 '이탈 의심'으로 정의했어요

59,946명

분석에 활용한 전체 사용자


31개

원본 컬럼 수

TARGET

이탈 기준은 왜 30일일까?

미접속 기간을 임의로 정하지 않고, 6가지 기준으로 사용자 분포를 비교했어요



너무 짧으면

일시적인 미접속까지 이탈에 포함돼요 (7일 40.5%)

너무 길면

이탈 데이터가 지나치게 줄어듭니다 (180일 8.0%)

30일 → 15,419명 (25.72%)

“사용자의 프로필 정보만으로 장기 미접속 위험을 미리 예측할 수 있을까?”

APPROACH

전체 SHAP과 개인별 SHAP

CatBoost 모델로 사용자별 장기 미접속 위험 확률을 예측하고, SHAP으로 '왜 그렇게 예측했는지'를 확인했어요

전체 SHAP (Global)

모델 전반에서 중요한 변수

- 자녀 관련 정보
- 식단 정보
- 자기소개 작성량과 작성 패턴

개인별 SHAP (Local)

같은 High Risk라도 위험 요인은 사람마다 달라요

- 사용자 A: 자기소개 작성량 부족이 가장 큰 요인
- 사용자 B: 자녀 관련 정보가 더 크게 작용


→ 각 개인의 위험도를 높인 상위 요인 3개를 추출

전체적으로 중요한 변수가 모든 사용자에게 똑같이 적용되지는 않는다

APPROACH

해결 방향 · 전체 서비스 흐름

예측에서 끝나지 않고, 그 결과를 실제 고객 관리에 활용할 수 있도록 초점을 맞췄어요



위험 등급과 개인별 예측 근거를 바탕으로 리텐션 전략을 제안하고, 실제 서비스에서는 A/B 테스트로 효과를 검증해요

DATASET & TARGET

데이터셋 및 이탈 기준

59,946명

Kaggle OkCupid Profiles

31개

원본 컬럼 수

15,419명

이탈 의심 (25.72%)

Target 정의

- last_online(마지막 접속 시각)으로 Target을 직접 생성
- 기준 시각에서 30일 이상 미접속 → 이탈 의심(1), 그 외 → 0
- 실제 탈퇴, Like · 매칭 · 메시지 같은 행동 로그는 데이터에 없음

Train / Test 분할 (75 : 25)



Train 44,959명

Test 14,987명

stratify 적용 → 두 데이터 모두 이탈 비율 25.72%

last_online은 Target 생성에 쓰인 정보라서 학습 Feature에서 제외 — 정답을 그대로 학습하는 데이터 누수 방지

EDA — 프로필을 충실히 쓸수록 덜 떠난다

프로필 완성도 5개 구간별 이탈 의심률 (평가 데이터)

약 3.4배

35.4%

가장 적게 채운 구간

10.5%

가장 많이 채운 구간

자기소개는 '작성 여부'만 보지 않고 4가지 파생 변수로 만들었어요

작성한 칸 수

`essay_count`

전체 단어 수

`essay_total_words`

평균 길이

`essay_avg_len`

칸별 길이 편차

`essay_len_std`

결측값도 하나의 신호다

자녀 관련 항목 응답 여부별 이탈 의심률

31.92%

무응답

16.7%

응답

결측값은 단순한 오류가 아니라, 사용자 행동 특성과 함께 나타나는 정보예요

결측이 있는 행을
삭제하지 않음

범주형 결측
→ '응답하지 않음'
(not_disclosed)

수치형 결측
→ NaN 유지
(CatBoost가 직접 처리)

모델 비교와 CatBoost 선택

모델	Accuracy	Precision	Recall	F1	ROC-AUC	해석
Logistic Regression	0.65350	0.39961	0.69079	0.50632	0.72869	Recall 우수, 오탐 많음
Random Forest	0.71749	0.45748	0.52892	0.49062	0.73108	Precision ↑, Recall ↓
XGBoost	0.67225	0.41602	0.67912	0.51596	0.74095	AUC·F1 경쟁력
LightGBM	0.66818	0.41249	0.68353	0.51450	0.73965	XGB와 유사
CatBoost	0.66838	0.41424	0.69857	0.52008	0.74146	후보 중 균형 우수
MLP	0.75746	0.58634	0.19377	0.29128	0.73028	Accuracy 높지만 Recall 매우 낮음

MODELING

모델 비교와 CatBoost 선택

Logistic
Regression

Random
Forest

XGBoost

LightGBM

CatBoost

MLP

6개 모델을 같은 조건으로 비교 → CatBoost 선택

ROC-AUC · F1 가장 높음

다만 XGBoost, LightGBM과 차이는 작아서 성능만으로 고른 것은 아니에요

범주형 변수를 직접 처리

직업 · 학력 · 식단처럼 범주형이 많아서, 별도의 복잡한 인코딩이 필요 없어요

수치형 결측치 직접 처리

수치형 변수의 결측치를 따로 처리하지 않아도 학습이 가능해요

MODELING

학습 설정과 교차검증

하이퍼파라미터

Random Search + Bayesian
Search 탐색

최고 후보는 깊이 4, 6이었지만 기존 설정을 넘지 못함

트리 300 · 깊이 5 · 학습률 0.06

클래스 가중치

이탈 의심 25.7%로 클래스 불균형
가중치가 없으면 다수인 '유지'만 학습할
가능성

이탈 사용자에게 더 큰 가중치

5-Fold 교차검증

ROC-AUC만 보지 않고 PR-AUC,
Recall도 함께 확인
이탈을 놓치지 않는지가 중요한 문제

ROC-AUC 0.7369 · PR-AUC
0.4898

PERFORMANCE

최종 성능 (Test 14,987명)

0.7401

ROC-AUC

0.4853

PR-AUC

0.6939

Recall

0.4103

Precision

0.5157

F1-score

이탈 의심 3,855명 중 2,675명(약 69.4%)을 탐지했어요

Recall을 중요하게 확인

위험 사용자를 놓치는 False Negative를 줄이는 것이 서비스 목적에 중요해요

Precision 약 41% → 오탐 존재


자동 조치가 아니라 마케팅 담당자가 우선 확인할 사용자군을 '선별'하는 도구로 활용해요

분류 임계값 0.5 유지

낮추면 Recall은 오르지만 Precision · F1이 떨어지고 전체 개선 효과가 크지 않았어요

PERFORMANCE & SHAP

SHAP 해석



SHAP은 예측에 기여한 정도를 보여줄 뿐, 이탈의 원인을 증명하는 값은 아니에요

자녀 관련 항목은 결측률이 약 59% — '자녀 여부 때문에 이탈'이 아니라 프로필 응답 특성과 관련된 예측 신호로 해석했어요


SERVICE에서는 사용자 한 명마다 Local SHAP을 다시 계산해 보여줘요

LIVE DEMO

서비스 화면 — SERVICE

SERVICE

- 프로필을 입력하면 개인별 이탈 위험 확률과 Low / Medium / High 등급을 계산해요
- Local SHAP으로 이 사용자에게 가장 크게 영향을 준 상위 3개 신호를 함께 보여줘요
- 리텐션 전략은 두 단계: ① 등급별 공통 혜택 ② 사용자가 직접 개선할 수 있는 신호가 있을 때만 개인화 안내 추가
- 자녀 유무처럼 바꿀 수 없는 특성으로는 차등을 두지 않아요
- 예측 결과는 실시간 진단 테이블에 저장돼 운영 이력으로 활용해요




LIVE DEMO

서비스 화면 — INSIGHT

INSIGHT


- 개별 사용자가 아니라 전체 사용자군의 패턴을 확인해요
- 위험군 분포와 함께 연령대 · 관계 상태 · 자기소개 작성량에 따라 실제 이탈 의심률이 어떻게 달라지는지 볼 수 있어요



서비스 화면 — RETENTION

RETENTION

- 위험 등급 · 프로필 완성도 · 자기소개 작성 수준 · 관계 상태 · 연령대를 조합해 관리 대상자를 조회해요
- 조건을 바꾸면 대상자 수 · 평균 이탈 확률 · 주요 위험 신호 · 우선 관리 대상자 목록이 함께 바뀌어요
- 모델의 예측 결과를 CRM 대상자 선정까지 연결한 화면이에요
- 위쪽 'A/B 시뮬레이션' 버튼 → 다음 슬라이드에서 설명



SQL TARGETING

머신러닝은 예측, SQL은 대상 선정

머신러닝

누가 이탈할 가능성이 높은지 예측

SQL

예측 결과를 바탕으로 어떤 사용자를 관리할지 조회하고 세분화

여러 조건을 조합해 캠페인 대상자를 선정해요

High Risk

+

프로필 완성도 낮음

+

자기소개 작성량 적음

→ 캠페인 대상자

모델이 위험을 잘 예측한다고 해서, 제안한 전략이 실제 이탈을 줄이는 것은 아니다 → 검증이 필요해요

A/B SIMULATION

A/B 테스트 운영 시뮬레이션



안 쓴 그룹은 기존 데이터의 실제 과거 기록이고, 쓴 그룹은 효과를 가정해서 만든 값이에요

⚠ 65.9%는 실제 결과가 아니에요 — 캠페인 적용 이후의 행동 로그가 없어서 효과를 가정했어요

A/B SIMULATION

효과를 가정하는 두 가지 시나리오

낙관 시나리오

가정한 효과 15.5%p

자기소개 분량에 따른 관찰 이탈률 격차 31.03%p의 절반만 효과로 반영했어요 (관찰된 차이는 상관관계라 전부 효과로 볼 수 없어요)

전략 쓴 그룹 65.9%

두 그룹의 차이 +15.7%p

보수 시나리오

가정한 효과 7%p

팀의 검정력 분석에서 현재 표본으로 안정적으로 발견할 수 있는 최소 효과 크기를 가정했어요

전략 쓴 그룹 57.4%


두 그룹의 차이 +7.2%p

두 값 모두 '예상되는 효과'가 아니라 시나리오를 만들기 위한 가정이에요

A/B SIMULATION

이 시뮬레이션이 보여주는 것

전략 효과를 보여주는 화면이 아니라, 실제 서비스 데이터가 들어왔을 때 검증이 어떻게 이어질 수 있는지 보여주는 구조예요



LIMITS

한계 ① Target — 이탈이 곧 탈퇴는 아니다

30일 미접속 $\neq$ 탈퇴

- 원본 데이터에 실제 탈퇴 여부가 없어서, 30일 이상 미접속한 사용자를 '이탈 의심'으로 정의했어요
- 그래서 모델이 예측하는 것은 실제 탈퇴가 아니라 '장기 미접속 위험'이에요
- 연애에 성공해서 앱을 떠난 사용자처럼 서비스에 불만이 없는 경우도 이탈 의심으로 분류될 수 있어요

LIMITS

한계 ② 행동 데이터와 데이터의 시대

행동 로그가 없어요

Like · Match · Message ·
접속 횟수 · 세션 같은 실제 서
비스 행동 데이터가 없어요

가상 행동 데이터는 쓰지 않았 어요

생성 방식에 따라 결과가 달라지
고 실제 성능이라 보기 어려워서,
대신 확장 구조를 제시했어요

2012년 샌프란시스코 데이터

국내 데이팅 서비스에 그대로 일
반화하기 어려워요. 최신 국내 데
이터로 재학습 · 검증이 필요해요

LIMITS

한계 ③ 모델 해석 시 주의할 점

오탐이 적지 않아요

Recall 약 69%, Precision 약 41%

자동 판단이 아니라 관리 대상자를 우선 선별하는 도구로 활용하고, 비용 · 고객 피로도를 고려해 임계값을 다시 조정해야 해요

Test 데이터를 여러 번 썼어요

Feature 정리 과정에도 사용

실제 성능은 별도의 독립 평가 데이터로 다시 확인해야 해요

확률은 절대값이 아니에요

예측 77.9% 구간의 실제 이탈률 55.9%

가중치를 줘서 확률이 높게 나와요. 순위는 정확해서 확률 숫자보다 등급과 순위 중심으로 활용해요

FUTURE WORK

향후 확장 방향

지금

프로필 기반 초기 예측

프로필 정보만으로 초기 위험 사용자를 예측



다음

프로필 + 행동 데이터

사용자 ID를 기준으로 Like · Match · Message · 접속 횟수를 연결한 예측 모델



그다음

전략 효과까지 학습

쌓인 행동 데이터와 캠페인 결과로 어떤 사용자에게 어떤 전략이 효과적이었는지 학습

프로필 기반 예측에서 → 실제 행동까지 반영하는 리텐션 시스템으로

CONCLUSION

결론

본 분석은 실제 개입 효과를 증명한 것이 아니라, 이탈 고위험군을 선별하고 향후 A/B 테스트를 설계하기 위한 사전 검증입니다. 실제 효과와 수익성은 서비스 환경에서 추가로 확인해야 합니다.

Catch는 단순히 이탈 확률만 보여주는 모델이 아니라,

**위험 사용자를 조기에 발견하고 → 예측 근거를 확인하고 → SQL로 관리 대상자를 선정하고
→ 리텐션 전략과 검증까지 연결한 B2B 고객 이탈 관리 서비스입니다.**

감사합니다